

IF2211 Strategi Algoritma
**Pengembangan Pipeline Model Fraud Classification dengan *Text Similarity*,
Fraud Classifier, dan *Explainable AI***

Laporan Tugas Besar

Disusun untuk memenuhi tugas mata kuliah Pemrosesan Bahasa Alami
pada Semester 1 (satu) Tahun Akademik 2025/2026



Disusun oleh:

Rizqika Mulia Pratama (13522126)
Auralea Alvinia Syaikha (13522148)
Mohamad Akmal Ramadan (13522161)

**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

**BANDUNG
2025**

1. Deskripsi Aplikasi + Data

Deskripsi Aplikasi

Aplikasi yang dikembangkan adalah sistem klasifikasi teks otomatis untuk mendeteksi pesan penipuan (*scam detection*) dalam Bahasa Indonesia. Sistem ini dirancang untuk memproses pesan singkat (SMS/Chat) seperti "Selamat! Anda menang hadiah 10jt. Klik link ini" dan mengkategorikannya ke dalam tiga kelas:

- a. **Scam:** Pesan penipuan yang bertujuan merugikan pengguna (contoh: undian palsu, permintaan transfer).
- b. **Not Scam:** Pesan sah/resmi (contoh: notifikasi OTP, pemberitahuan pengiriman paket).
- c. **Neutral:** Percakapan sehari-hari yang tidak mengandung unsur transaksional atau penipuan.

Aplikasi ini terdiri dari beberapa komponen utama:

1. **Preprocessing Teks:** Melakukan normalisasi teks Bahasa Indonesia (slang, lowercase, stopword removal, stemming) agar siap diproses model.
2. **Text Classification:** Menggunakan model machine learning (seperti IndoBERT) untuk mengklasifikasikan input teks ke dalam kelas scam, not scam, atau neutral.
3. **Text Similarity (Opsional):** Menghitung kemiripan semantik antara input dan kumpulan pesan scam untuk mendukung deteksi dan analisis.
4. **Explainable NLP Model:** Menyediakan penjelasan (explanation) mengapa sebuah pesan terdeteksi sebagai fraud/scam, misalnya dengan menampilkan kata-kata kunci, fitur penting, atau highlight bagian teks yang berkontribusi pada keputusan model (menggunakan teknik XAI seperti LIME, SHAP, atau attention visualization).

Aplikasi ini membantu pengguna memahami tidak hanya hasil klasifikasi, tetapi juga alasan di balik keputusan model, sehingga meningkatkan transparansi dan kepercayaan terhadap sistem.

Deskripsi Data

Dataset yang digunakan terdiri dari kumpulan pesan teks dalam Bahasa Indonesia, mencakup berbagai gaya bahasa (formal hingga slang) dan konteks percakapan.

- **Sumber Data:** Data dibuat dengan mengumpulkan teks yang beredar di publik dan terindikasi *scam*.

Kami juga menambahkan data sintetis tambahan untuk memperbanyak dataset dengan men-*generate* melalui LLM. Validasi terhadap data sintetis yang di-*generate* dilakukan secara manual dan *cross validation* antar LLM..

- **Jumlah Data:** Total 1.503 baris data.
- **Prosedur Labeling (QA):**
 - Data dilabeli secara manual oleh annotator dengan validasi silang (cross-validation) untuk memastikan konsistensi label.
 - Setiap pesan diperiksa konteksnya untuk membedakan antara promosi marketing sah dan penipuan.

2. BEAM Notation

Berikut adalah perancangan sistem menggunakan notasi BEAM (*Business, Environment, Analytics, Model, Data*):

Komponen	Deskripsi
B (Business)	Masalah: Meningkatnya kasus penipuan digital melalui pesan singkat di Indonesia. Tujuan: Meminimalkan kerugian finansial pengguna dengan menyaring pesan berbahaya secara otomatis.
E (Environment)	Sistem: Aplikasi berjalan sebagai layanan <i>backend</i> (API) atau bot yang menerima input teks. Pengguna: Pengguna umum aplikasi pesan atau penyedia layanan telekomunikasi.
A (Analytics)	Metode: <i>Predictive Analytics</i> (Klasifikasi Teks). Metrik: Mengutamakan <i>Recall</i> pada kelas Scam

Diagram di atas mengilustrasikan alur sistem mulai dari masalah bisnis (Business) yang diterjemahkan menjadi kebutuhan analitik (Analytics), didukung oleh data (Data) yang diproses melalui model IndoBERT (Model), hingga akhirnya dideploy ke lingkungan produksi (Environment) untuk digunakan oleh pengguna akhir.


3. Exploratory Data Analysis (EDA)

Sebelum pemodelan, dilakukan analisis terhadap distribusi data untuk memastikan keseimbangan kelas.

Distribusi Kelas:

Dataset memiliki distribusi yang cukup seimbang (balanced), sehingga tidak memerlukan teknik oversampling atau undersampling.


- **Neutral:** 520 data
- **Not Scam:** 495 data
- **Scam:** 488 data
- **Total:** 1.503 data




Sampel Data Mentah:

- *Scam:* "INFO RESMI: Selamat No.Anda terpilih pemenang..."
- *Not Scam:* "Yth. Nasabah, kartu ATM Anda terblokir karena..."
- *Neutral:* "Udah liat pengumuman nilai ujian kemarin belum?"


Statistik Teks:



- Pesan Scam cenderung memiliki penggunaan huruf kapital berlebih (Caps Ratio) tinggi sebagai indikasi urgensi.



- Pesan Scam memiliki jumlah kata yang lebih singkat dibandingkan pesan netral dan Not Scam.



- Pesan scam lebih banyak menggunakan tanda seru untuk mempertegas konteks.

Word Cloud Analysis:



- Scam: Didominasi kata: “selamat”, “hadiah”, “segera”, “rekening”.
- Not Scam: Didominasi kata “berhasil”, “terima kasih”, “saldo”.
- Neutral: Didominasi kata percakapan sehari-hari seperti “yang”, “tidak”, “saya”, “banget”, “buat”, “ya”.

4. Penjelasan Data Preprocessing

Mengingat IndoBERT dilatih pada Bahasa Indonesia baku (Wikipedia/Berita), sedangkan data pesan singkat mengandung banyak *noise* dan bahasa gaul, tahap preprocessing sangat krusial.

Langkah-langkah yang dilakukan:

1. **Case Folding:** Mengubah seluruh huruf menjadi huruf kecil (*lowercase*).
2. **Cleaning (Regex):**
 - Menghapus URL (<http://...>).
 - Menghapus nomor telepon (disensor menjadi spasi) untuk privasi dan generalisasi.
 - Menghapus karakter non-alfanumerik/tanda baca berlebih.
3. **Slang Normalization (Penting):**
 - Menggunakan kamus *slang* kustom untuk mengubah kata tidak baku menjadi baku.
 - Contoh: "gw" menjadi "saya", "trf" menjadi "transfer", "tlg" menjadi "tolong".
 - Tujuannya agar *tokenizer* IndoBERT dapat mengenali kata tersebut dengan benar.
4. **Tokenization:**
 - Menggunakan AutoTokenizer dari indobenchmark/indobert-base-p1.
 - Padding dan Truncation diatur ke panjang maksimal 128 token.

5. Desain Eksperimen

Eksperimen dilakukan dengan teknik *Transfer Learning* (Fine-tuning).

- **Model Pre-trained:** indobenchmark/indobert-base-p1 (Hugging Face).
- **Pembagian Data (Split):**
 - Train: 70% (1.052 sampel)
 - Validation: 15% (225 sampel)
 - Test: 15% (226 sampel)
 - Menggunakan *Stratified Split* untuk menjaga proporsi kelas.
- **Hyperparameters:**
 - Epochs: 5
 - Batch Size: 16 (Train), 32 (Eval)
 - Learning Rate: 2e-5
 - Weight Decay: 0.01
 - Optimizer: AdamW (default Trainer Hugging Face)
- **Hardware:** GPU T4 (Google Colab).
- **Strategi Evaluasi:** Menggunakan metrik Accuracy, Precision, Recall, dan F1-Score (Macro Average). Menggunakan *Early Stopping* jika *loss* validasi tidak membaik setelah 3 langkah evaluasi.

6. Hasil Eksperimen

Model menunjukkan performa yang sangat tinggi pada *Test Set*.

Metrik Kuantitatif:


- **Akurasi (Accuracy):** 98.67%
- **F1-Score:** 98.66%
- **Loss Validasi Akhir:** ~0.005

Laporan Klasifikasi (Classification Report):

Kelas	Precision	Recall	F1-Score	Support
Not Scam	0.99	0.99	0.99	75

Neutral	1.00	0.99	0.99	78
Scam	0.97	0.99	0.98	73

Visualisasi Confusion Matrix:



Model berhasil memprediksi hampir semua sampel dengan benar. Kesalahan prediksi sangat minim (hanya 1-2 sampel yang salah klasifikasi antar kelas), menunjukkan model sangat robust.

7. Analisis Hasil Eksperimen

Berdasarkan hasil eksperimen di atas, dapat disimpulkan beberapa poin analisis:

1. **Efektivitas IndoBERT:** Penggunaan model bahasa besar (*Large Language Model*) spesifik Bahasa

Indonesia (IndoBERT) terbukti sangat efektif dibandingkan metode tradisional. Model mampu menangkap konteks kalimat, bukan hanya kata kunci.

2. **Dampak Preprocessing:** Normalisasi *slang* berperan besar dalam meningkatkan akurasi. Tanpa normalisasi, kata seperti "trf" atau "rek" mungkin dianggap token tidak dikenal (*unknown*), namun setelah dinormalisasi menjadi "transfer" dan "rekening", model memahami konteks penipuan keuangan.
3. **Analisis Kesalahan (Error Analysis):**
 - Model memiliki **Recall tinggi pada kelas Scam (0.99)**. Ini adalah hasil yang diinginkan untuk sistem keamanan, karena berarti hampir tidak ada pesan penipuan yang lolos (minim *False Negative*).
 - Sedikit kesalahan mungkin terjadi pada pesan yang ambigu atau mengandung kata kunci penipuan tetapi dalam konteks bercanda/netral, namun jumlahnya tidak signifikan.
4. **Analisis Explainable AI (LIME):** Pengujian dengan LIME menunjukkan model mengambil keputusan berdasarkan fitur yang benar.
 - *Contoh:* Pada kalimat "Selamat Anda menang undian", LIME menyoroti kata "**menang**" dan "**undian**" sebagai kontributor utama label *Scam*. Ini membuktikan model tidak bias pada fitur yang salah.
5. **Analisis Text Similarity:** Fitur kemiripan teks berhasil mendeteksi pola berulang. Pesan penipuan baru yang hanya diubah sedikit strukturnya (misal: "Selamat!" menjadi "Info Resmi!") tetap terdeteksi memiliki skor *similarity* tinggi (>0.85) terhadap database *scam*, memberikan lapisan keamanan ganda.
6. **Uji Coba Manual (Inference Demo):**
 - Input: "Selamat! Anda menang hadiah 10 juta. Klik link ini." → Prediksi: **SCAM** (99.8%).
 - Input: "Shopee: Paket Anda sudah sampai di hub terdekat." → Prediksi: **NOT SCAM** (99.9%).
 - Input: "Gue lagi cari laptop buat kuliah nih." → Prediksi: **NEUTRAL** (99.9%).

Secara keseluruhan, model siap untuk di-*deploy* dan diintegrasikan ke dalam sistem produksi.

Lampiran

- **Link Video Demo:**  Demo Tubes NLP Kelompok 14.mov
- **Link Repository (Github):** https://github.com/auraleaas/ScamDetection_NLP
- **Link Notebook (Google Colab):**  fraud_classification_model.ipynb